

DataSynthesizer、Utility Measures 与合成表格数据综述精读拆解及毕设关联说明

本文针对说明书中第 4、5 条经重新检索后最可能对应的三篇文献进行梳理：

1. Ping H., Stoyanovich J., Howe B. **DataSynthesizer: Privacy-Preserving Synthetic Datasets**. SSDBM 2017.

2. Snok J., Raab G., Nowok B., Dibben C., Slavković A. **General and Specific Utility Measures for Synthetic Data**. JRSS Series A, 2018.

3. Shi R. S., Wang Y., Du M., Shen X., Chang Y., Wang X. **A Comprehensive Survey of Synthetic Tabular Data Generation**. arXiv 2025.

这三篇文献分别补足你毕设中的三个部分：

- **DataSynthesizer**：早期隐私保护合成表格数据系统，帮助理解统计型合成器和隐私-效用权衡。
- **General and Specific Utility Measures**：合成数据质量/效用评估的经典方法，尤其是 pMSE、general utility、specific utility。
- **A Comprehensive Survey**：近年合成表格数据生成综述，帮助把 CTGAN/TVAE、扩散模型、LLM 生成放进完整技术谱系。

1. DataSynthesizer: Privacy-Preserving Synthetic Datasets

1.1 基本信息

正式引用：

Haoyue Ping, Julia Stoyanovich, Bill Howe.

DataSynthesizer: Privacy-Preserving Synthetic Datasets.

Proceedings of the 29th International Conference on Scientific and Statistical Database Management, SSDBM 2017.

DOI: <https://doi.org/10.1145/3085504.3091117>

说明书中原写法是 Ping H., et al. Data Synthesis based on Data Utility. ICDE 2019，但经检索并没有找到完全对应的论文。若按照作者 Ping H. 和“早期合成数据质量评估/生成系统”判断，最可能对应的是这篇 DataSynthesizer。

1.2 这篇文章解决什么问题

这篇论文关注的是：

当真实数据涉及隐私、法律或共享协议限制时，如何生成一份结构和统计特征类似、但不泄露个人敏感信息的合成数据集？

在许多场景中，数据拥有者不能直接把原始数据交给外部分析人员。例如医院、政府机构或社会科学数据通常涉及隐私。传统数据共享协议周期长、成本高，导致协作困难。

DataSynthesizer 的目标是让数据拥有者可以先发布一份合成数据，使外部研究人员能够先开发方法、熟悉数据结构、验证分析流程，同时降低隐私泄露风险。

1.3 核心思路

一句话概括：

DataSynthesizer 先从原始表格中学习带差分隐私保护的数据摘要，再从该摘要中采样生成合成数据，并提供可视化检查工具比较真实数据与合成数据的统计相似性。

系统由三个模块组成：

1. **DataDescriber**：读取原始 CSV，推断字段类型、取值域、分布、缺失率和属性相关性，并在需要时加入差分隐私噪声。
2. **DataGenerator**：根据 DataDescriber 生成的数据描述文件采样，生成指定数量的合成记录。
3. **ModelInspector**：比较原始数据和合成数据的统计摘要，例如直方图、类别分布、KL divergence、pairwise mutual information 和 Bayesian network。

1.4 三种生成模式

DataSynthesizer 提供三种模式。

Random mode：只生成类型一致的随机值。例如年龄仍是整数，日期仍是日期，但不保证分布相似。它隐私强，但效用很低。

Independent attribute mode：每列独立建模。类别列用频率分布，数值列用直方图，然后对每列独立采样。它能保留单列分布，但不能保留列与列之间的关系。

Correlated attribute mode：用差分隐私 Bayesian network 建模属性之间的依赖关系，再按网络顺序采样。它比独立模式更能保留多列相关性。

1.5 和你毕设的关系

DataSynthesizer 对你的毕设有三点价值。

第一，它是一个早期统计型合成数据生成器。你的基准除了 CTGAN/TVAE 这类深度生成器，也可以考虑加入 GaussianCopula、Bayesian network 或 DataSynthesizer 这类统计方法作为“较易检测”的合成污染源。

第二，它展示了如何检查合成数据和真实数据是否“像”。ModelInspector 使用直方图、KL divergence、相关矩阵和 Bayesian network 对比，这些思想可以直接服务于你的统计检测基线和数据卡。

第三，它强调隐私与效用的权衡。差分隐私噪声越强，隐私越好，但统计相似性和下游效用可能下降。这和你毕设中“合成污染对下游效用/数据价值的影响”直接相关。

2. General and Specific Utility Measures for Synthetic Data

2.1 基本信息

正式引用：

Joshua Snoke, Gillian M. Raab, Beata Nowok, Chris Dibben, Aleksandra Slavković.

General and Specific Utility Measures for Synthetic Data.

Journal of the Royal Statistical Society: Series A, 2018.

DOI: <https://doi.org/10.1111/rssa.12358>

这篇论文非常适合补充说明书里“Data Utility / 早期合成数据质量评估”这一方向。

2.2 这篇文章解决什么问题

这篇论文关注的是：

合成数据生成之后，如何判断它是否足够有用？

合成数据的目标不是和原始数据逐行相同，而是希望在保护隐私的同时保留足够的分析价值。因此需要评价合成数据的 utility。

论文把 utility 分为两类：

- **General utility**：合成数据整体分布是否接近真实数据。
- **Specific utility**：针对某个具体分析任务，合成数据得出的结论是否接近真实数据。

2.3 核心思路

一句话概括：

论文用 propensity score mean-squared error (pMSE) 衡量真实数据和合成数据的整体可区分性，并用置信区间重叠与标准化系数差异衡量具体分析结果的一致性。

2.4 General utility: pMSE

pMSE 的思想非常适合你的课题。

做法是：

1. 把真实数据和合成数据堆在一起。
2. 给真实数据标记 0，合成数据标记 1。
3. 训练一个分类器预测某条记录来自真实数据还是合成数据。
4. 如果分类器很难区分，说明合成数据整体分布更接近真实数据。
5. 如果分类器很容易区分，说明合成数据与真实数据差异较大。

pMSE 衡量的是预测概率与理论比例之间的均方差。若真实和合成样本数量相同，理想情况下每条记录被判为合成的概率应接近 0.5。

这与本题“样本级 real/synthetic 检测”高度相关。你的检测任务可以看成把 pMSE 的“合成数据质量评估视角”反过来用：如果一个分类器能稳定地区分真实和合成数据，就说明存在可检测的合成污染痕迹。

2.5 Specific utility

Specific utility 关注具体分析结果是否一致。

论文使用了两类指标：

- **Confidence interval overlap**：真实数据和合成数据中同一统计量/模型系数的置信区间重叠程度。

- **Standardized difference**: 真实数据估计值和合成数据估计值之间的标准化差异。

对你的毕设来说，这对应任务三：

合成污染是否改变下游模型性能或分析结论？

你可以用更机器学习化的指标替代原文统计指标，例如 AUROC、F1、accuracy、回归 R^2 等。

2.6 和你毕设的关系

这篇论文对你的价值很直接：

1. 它提供了 real-vs-synthetic 分类器作为合成数据质量评估的理论依据。
2. 它解释了为什么“能否区分真实/合成”本身就是一种 utility/fidelity 信号。
3. 它提醒你不能只看单一指标，应同时关注整体分布相似性和具体下游任务表现。
4. 它可以作为你阶段一“SDMetrics + sklearn 分类器跑 AUROC”的理论来源之一。

3. A Comprehensive Survey of Synthetic Tabular Data Generation

3.1 基本信息

正式引用：

Ruxue Shi, Yili Wang, Mengnan Du, Xu Shen, Yi Chang, Xin Wang.
A Comprehensive Survey of Synthetic Tabular Data Generation.
arXiv 2025.
<https://arxiv.org/abs/2504.16506>

这篇综述适合替代说明书第 5 条中“近年相关综述 / 基准，检索确认”的部分。

3.2 这篇文章解决什么问题

这篇综述关注的是：

合成表格数据生成领域有哪些主要方法、完整流程、评价方式、应用场景和未来挑战？

它试图把分散的研究整合成一个完整框架，尤其补充了近年来扩散模型和 LLM 方法在表格生成中的发展。

3.3 核心思路

一句话概括：

该综述将合成表格数据生成方法划分为传统方法、扩散模型方法和 LLM 方法，并从生成、后处理、评估、应用和未来方向多个层面梳理整个技术管线。

3.4 论文总结的主要挑战

综述指出表格生成面临几类挑战。

数据质量挑战：

- 数据量小。

- 类别不平衡。
- 缺失值普遍。

表格固有特性挑战：

- 数值列和类别列混合。
- 特征之间依赖复杂而稀疏。
- 单列中可能存在混合类型。

分布复杂性挑战：

- 数值特征非高斯。
- 有偏态、长尾、多峰分布。
- 不同列有不同尺度和语义。

这些挑战和 CTGAN 论文中的问题高度一致，也解释了为什么本题不能只做简单随机生成。

3.5 方法分类

综述把方法分为三大类。

传统生成方法包括 Copula、Bayesian network、SMOTE、Synthpop、VAE、GAN、CTGAN、TVAE、TableGAN、CTAB-GAN 等。

扩散模型方法包括 TabDDPM、TabDiff、TabSyn 等，优点是训练稳定、能处理复杂分布，缺点是计算成本通常较高。

LLM-based 方法包括 prompt-based 和 fine-tuning 两类，如 GReaT、TabuLa、TabMT、AIGT、DP-LLMTGen 等。它们的优势是可以利用语言模型的语义和常识知识，但也可能产生幻觉、不合法值和格式错误。

3.6 后处理与评估

综述特别强调生成后的后处理：

- sample filtering：过滤不合理样本。
- sample correction：根据规则或约束修正样本。
- label enhancement：修正合成样本标签。

这对你的毕设有启发。你构建污染基准时，合成数据不能太假，也不能有明显越界或非法类别，否则检测会变得过于简单。

评估方面，综述将指标分为：

- **ML efficiency**：TSTR，即用合成数据训练，在真实测试集上测试。
- **Fidelity**：列分布、联合分布、Wasserstein、KS、JSD、TVD 等。
- **Alignment**：是否违反领域约束或常识规则。
- **Privacy**：DCR、membership inference、attribute inference 等。

3.7 和你毕设的关系

这篇综述可以帮你确定整个课题的技术版图。

它说明：

- CTGAN/TVAE 是经典起点，但不是全部。
- 近年扩散模型和 LLM 生成正在成为重要方向。
- 合成数据评估不能只看统计相似性，还要看下游效用、约束一致性和隐私风险。
- 后处理和质量过滤是构建高质量基准的必要步骤。

对你的毕设而言，这篇综述适合放在文献综述中作为“合成表格数据生成发展脉络”的总览文献，并帮助说明为什么你的基准要覆盖多类生成器、多个污染比例和多种评价维度。

4. 三篇文献如何补充已有五篇

已有五篇文献中，CTGAN/TVAE 负责深度生成器，模型坍塌负责动机，ZeroED 负责 LLM 检测范式，Data Shapley 负责估值工具。

这三篇补充后，文献体系更完整：

- **DataSynthesizer** 补充早期统计型、差分隐私型合成器。
- **General and Specific Utility Measures** 补充合成数据 utility/fidelity 的经典评价方法。
- **A Comprehensive Survey** 补充近年方法全景，尤其是扩散模型、LLM 生成、后处理与评估。

这样你的文献综述可以形成如下结构：

合成表格数据生成：DataSynthesizer -> CTGAN/TVAE -> 扩散模型/LLM 综述
合成数据质量评估：General/Specific Utility -> SDMetrics -> XAI 诊断
合成污染风险动机：模型坍塌
LLM 检测范式：ZeroED
估值影响分析：Data Shapley

5. 可写进综述的整合段落

可以这样写：

早期合成表格数据研究主要围绕隐私保护和统计相似性展开。Ping 等人提出的 DataSynthesizer 通过 DataDescriber、DataGenerator 和 ModelInspector 三个模块，从原始表格中学习带差分隐私保护的数据摘要，并生成结构和统计特征相似的合成数据，为隐私敏感数据共享提供了实用工具。与之相配套，Snoke 等人系统讨论了合成数据的 general utility 和 specific utility，提出基于 propensity score mean-squared error 的整体效用评估方法，并使用置信区间重叠和标准化系数差异衡量具体分析任务的一致性。这些工作为评估合成数据是否“像真实数据”以及是否支持下游分析提供了基础。

近年来，合成表格数据生成方法不断扩展。Shi 等人的综述将现有方法归纳为传统生成方法、扩散模型方法和 LLM-based 方法，并指出表格数据由于混合类型、类别不平衡、缺失值、复杂依赖关系和非高斯分布等特点，仍然难以高质量生成。该综述还强调了后处理、ML utility、fidelity、alignment 与 privacy 等评估维度。本文在上述工作的基础上，不再只关注如何生成合成数据，而进一步研究合成数据混入真实数据后的检测、比例估计及其对数据价值的影响。