

模型坍塌、ZeroED 与 Data Shapley 论文精读拆解及毕设关联说明

本文针对说明书中第 6-8 篇文献进行梳理：

6. Shumailov I., et al. **AI models collapse when trained on recursively generated data**. Nature, 2024.

7. Ni W., Zhang K., Miao X., et al. **ZeroED: Hybrid Zero-Shot Error Detection Through Large Language Model Reasoning**. ICDE, 2025.

8. Ghorbani A., Zou J. **Data Shapley: Equitable Valuation of Data for Machine Learning**. ICML, 2019.

这三篇论文分别对应你毕设中的三个关键支点：

- **模型坍塌论文**：解释为什么“合成污染”值得研究，是课题动机。
- **ZeroED**：提供 LLM 赋能表格检测的组内范式，是你方法④的直接参考。
- **Data Shapley**：提供数据估值的理论和工具，是任务三“估值影响分析”的基础。

0. 三篇论文在你毕设中的位置

你的毕设题目是：

合成表格数据污染检测：基准构建、LLM 赋能检测与数据估值影响分析

这三篇文献刚好分别支撑题目的不同部分。

文献	主要研究对象	在毕设中的作用
AI models collapse when trained on recursively generated data	模型反复训练于合成数据会退化	说明为什么合成数据混入训练集是风险
ZeroED	LLM + ML 做表格错误检测	借鉴 LLM 如何参与表格数据检测
Data Shapley	衡量单条训练数据的价值	分析合成污染如何影响数据价值

如果说 CTGAN/TVAE 回答“合成表格数据从哪里来”，那么这三篇分别回答：

- 为什么要警惕合成数据反复进入训练管线？
- 怎么把 LLM 用到表格检测任务中？
- 怎么量化数据对模型性能的贡献？

第一篇：AI models collapse when trained on recursively generated data

1. 基本信息

正式引用：

Shumailov, I., Shumaylov, Z., Zhao, Y., Papernot, N., Anderson, R., Gal, Y.
AI models collapse when trained on recursively generated data.
Nature 631, 755-759, 2024.
DOI: <https://doi.org/10.1038/s41586-024-07566-y>

这是一篇 Nature 论文，讨论生成式 AI 时代一个很重要的问题：

如果未来互联网上充满 AI 生成内容，而下一代模型又继续用这些内容训练，会发生什么？

论文的回答是：可能发生 **model collapse**（模型坍塌）。

2. 论文核心问题

过去的大模型大多训练在人类生成的数据上，例如：

- 人写的网页。
- 真实论坛讨论。
- 人类创作的书籍。
- 真实图像和说明。

但现在 AI 生成内容越来越多。未来训练数据中很可能混入大量模型生成内容。

论文关心的是：

当第 1 代模型用真实数据训练，第 2 代模型用第 1 代模型生成的数据训练，第 3 代模型又用第 2 代模型生成的数据训练，如此递归下去，模型会不会越来越差？

论文发现：会。并且这种退化不是偶然现象，而是生成模型递归训练中普遍存在的风险。

3. 什么是模型坍塌

论文给出的定义可以用大白话理解为：

模型坍塌是指生成模型反复使用前代模型生成的数据训练后，逐渐忘记真实数据分布，尤其先丢失低概率、长尾、少数群体的信息，最后生成结果变得越来越窄、越来越单一。

3.1 早期坍塌

早期坍塌表现为：

- 分布尾部消失。
- 少见事件被忽略。
- 少数群体信息减少。
- 模型生成内容越来越“平均”。

例如真实数据中有 1% 的罕见职业、罕见疾病、罕见收入组合。模型生成数据时可能没有采到它们。下一代模型继续训练，就更难恢复这些罕见模式。

3.2 后期坍塌

后期坍缩表现为：

- 方差越来越小。
- 样本越来越相似。
- 模型输出集中到少数模式。
- 最后与原始真实分布差距很大。

这就像不断复印一张图片，每一代都丢一点细节，最后图像变糊、变形。

4. 模型坍缩为什么会发生

论文总结了三类误差。

4.1 Statistical approximation error：统计近似误差

真实世界的数据分布是无限复杂的，但我们训练模型时只能采有限样本。

如果某个事件本来就很少见，那么有限采样时很可能采不到。采不到，就无法被下一代模型学习。

对你的毕设来说，这点很重要：

合成表格数据可能天然削弱少数类别和长尾组合。

例如金融数据中的少数违约人群、医疗数据中的罕见病人群，都可能在合成过程中被淡化。

4.2 Functional expressivity error：函数表达能力误差

模型能力有限，不能完美表达真实分布。

例如真实分布是两个复杂人群混合，但模型只能学成一个简单分布，就会丢失结构。

在表格数据中，这可能表现为：

- 学不准变量之间的复杂相关性。
- 学不准多峰分布。
- 学不准少数类别。

4.3 Functional approximation error：函数优化误差

即使模型理论上能表达真实分布，实际训练过程也可能学不到。

例如：

- 优化算法有偏差。
- 训练不充分。
- 损失函数不完全符合目标。
- 模型容易过拟合某些模式。

这也说明，合成数据生成器即使很先进，也不可能保证完美复制真实数据分布。

5. 论文用了哪些实验

论文从三个层面说明模型坍缩：

1. 离散分布的理论分析。
2. 高斯分布 / GMM / VAE 等较简单生成模型。
3. 语言模型 OPT-125M 在 WikiText-2 上的递归微调实验。

5.1 离散分布理论

论文说明：即使假设模型能完美学习当前样本分布，只要每一代都要重新采样，低概率事件就有概率消失。

一旦消失，下一代就更难恢复。

5.2 高斯模型坍缩

论文证明，在某些高斯近似场景中，递归训练会导致：

- 估计分布与原始分布距离越来越大。
- 方差趋近于 0。

这就是“越来越集中、越来越单一”。

5.3 语言模型实验

论文用 OPT-125M 在 WikiText-2 数据集上做实验：

1. 第 0 代模型用真实文本训练。
2. 第 1 代模型用第 0 代生成的文本训练。
3. 第 2 代模型用第 1 代生成的文本训练。
4. 继续递归。

实验中模型的 perplexity 和生成文本质量逐代恶化，后代模型会出现重复、跑题、语义混乱等现象。

6. 这篇论文和你的毕设有什么关系

这篇论文是你毕设的**根本动机**。

你的课题虽然不是研究文本模型坍缩，而是研究表格数据污染，但逻辑非常相似：

真实表格数据

- > CTGAN/TVAE/LLM 生成合成表格数据
- > 合成数据混入训练集或分析集
- > 下游模型/数据分析可能受到影响

模型坍缩论文提醒我们：

- 合成数据不是天然无害的。
- 合成数据可能削弱长尾信息。
- 合成数据可能改变真实分布。
- 必须区分真实数据和模型生成数据的来源。

你的毕设进一步把这个问题具体化到表格场景：

在表格数据进入训练或分析管线前，我们能不能检测它是否混入合成数据？能不能估计混入了多少？混入后会不会影响数据价值？

7. 综述中如何写这篇论文

短版可以这样写：

Shumailov 等人在 Nature 2024 中提出并分析了 model collapse 现象，即生成模型若递归地使用前代模型生成的数据进行训练，会逐渐丢失真实数据分布中的尾部信息，并最终产生不可逆的分布退化。该工作在理论和实验上展示了模型生成数据污染训练语料的风险，强调真实数据来源和数据 provenance 的重要性。本文研究的合成表格数据污染检测可视为该问题在结构化表格数据场景下的延伸，目标是在表格数据进入下游训练或分析管线前识别合成样本并量化污染比例。

第二篇：ZeroED

8. 基本信息

正式引用：

Wei Ni, Kaihang Zhang, Xiaoye Miao, Xiangyu Zhao, Yangyang Wu, Yaoshu Wang, Jianwei Yin.
ZeroED: Hybrid Zero-Shot Error Detection Through Large Language Model Reasoning.
ICDE 2025.
DOI: <https://doi.org/10.1109/icde65448.2025.00234>
arXiv: <https://arxiv.org/html/2504.05345v1>
GitHub: <https://github.com/WelkinNi/ZeroED>

这篇论文是组内工作，研究的是：

如何用大语言模型帮助检测表格数据中的错误。

它不是检测“合成数据”，而是检测“脏数据 / 错误单元格”。但它的方法范式和你的 LLM 赋能合成检测高度相关。

9. ZeroED 想解决什么问题

表格错误检测是数据清洗中的第一步。

表格错误可能包括：

- 缺失值。
- 拼写错误。
- 格式错误。
- 离群值。
- 违反跨列规则的值。

例如：

Name	Gender	Education	Salary
Alice	F	Bachelor	8000
DaveGreen	F	Bechxlor	6000

其中可能存在：

- **Bechxlor** 是拼写错误。
- **DaveGreen** 可能违反姓名格式。
- **Salary=6000** 可能是离群值。
- **Name** 和 **Gender** 之间可能存在规则冲突。

传统方法有两个问题：

1. 人工规则方法需要专家手写规则。
2. 机器学习方法需要大量人工标注。

LLM 看起来能减少人工成本，但如果直接问：

这条记录有没有错误？

效果有限，而且对大表逐条询问成本很高。

ZeroED 的目标就是：

用 LLM 的推理能力减少人工规则和人工标注，同时避免直接让 LLM 处理全量数据造成高成本。

10. ZeroED 的总体框架

ZeroED 是一个 hybrid framework，也就是“LLM + 传统机器学习”的混合框架。

它不是让 LLM 直接判断所有数据，而是让 LLM 参与几个关键环节，再训练一个普通分类器完成大规模检测。

整体分四步：

1. 特征表示。
2. 代表性数据采样与 LLM 标注。
3. 训练数据构建。
4. 训练检测器并预测。

11. 第一步：LLM 增强的特征表示

传统错误检测常用简单特征：

- 值出现频率。
- 字符模式。
- TF-IDF。
- 统计异常程度。

这些特征只能看到表层信息，不理解错误原因。

ZeroED 增加了三类信息：

11.1 统计特征

例如：

- 某个值在该列出现多少次。
- 某种字符模式出现多少次。
- 某个值和其他列值共同出现的频率。

11.2 语义特征

使用 FastText 等预训练 embedding，把单元格值转成语义向量。

例如 **Bachelor** 和 **Master** 在语义空间中可能比 **Bachelor** 和 **6000** 更接近。

11.3 LLM 生成的错误原因感知特征

这是 ZeroED 的关键。

ZeroED 会让 LLM 根据数据样例和字段含义生成可执行的检查规则，例如 Python 函数：

```
def check_salary(value):  
    return value > 0 and value < 1000000
```

或者跨列检查：

```
def check_arrival_departure(row):  
    return row["arrival_time"] >= row["departure_time"]
```

然后把这些规则执行结果变成二值特征。

这点对你的毕设非常有启发：

LLM 不一定只负责最终判断，也可以负责生成特征、规则、解释和标注。

12. 第二步：代表性采样与 LLM 标注

直接让 LLM 标注全表太贵。

ZeroED 的做法是：

1. 先用特征把数据聚类。
2. 每个簇选代表性样本。
3. 只让 LLM 标注这些代表样本。

这能显著降低 token 成本。

论文中还设计了检测指南生成流程：

- 先让 LLM 生成数据分析函数。
- 用函数分析全表分布。
- 再让 LLM 基于分析结果生成每个属性的错误检测指南。
- 最后让 LLM 根据指南标注代表样本。

这比简单 prompt 更强，因为 LLM 获得了更完整的数据上下文。

13. 第三步：训练数据构建

LLM 标注的样本数量有限，不能直接训练强检测器。

ZeroED 做了三件事：

13.1 簇内标签传播

同一聚类中的样本往往相似，因此可以把代表样本的标签传播给同簇样本。

13.2 互相验证

标签传播可能有错。ZeroED 用 LLM 生成/优化的检查规则和传播标签互相验证，过滤不可靠数据。

13.3 LLM 错误增强

错误样本通常少。ZeroED 让 LLM 生成更多语义合理的错误样例，缓解类别不平衡。

14. 第四步：训练普通分类器

最后 ZeroED 用构建好的训练数据训练一个 MLP 分类器，判断单元格是否错误。

这说明 ZeroED 的思想不是“LLM 取代机器学习”，而是：

LLM 负责提供高质量推理、规则和少量标注，机器学习负责低成本、大规模预测。

15. ZeroED 的实验结论

论文在 7 个数据集上实验，包括 Hospital、Flights、Beers、Rayyan、Billionaire、Movies、Tax。

比较方法包括：

- dBoost。
- Nadeef。
- Katara。
- ActiveClean。
- Raha。
- FM_ED。

主要结论：

- ZeroED 在多个数据集上取得更高 F1。
- 相比传统规则方法，ZeroED 更全面。
- 相比纯 LLM prompt 方法，ZeroED 更省 token、更稳定。
- 消融实验显示 guideline generation、criteria reasoning、correlated attributes 都有贡献。
- 大模型通常比小模型效果好，Qwen2.5-72B 表现较强。
- 聚类采样优于随机采样。

16. ZeroED 和你的毕设有什么关系

你的毕设中方法④是：

LLM 赋能检测合成表格数据。

ZeroED 正是最直接的参考。

不过你要检测的不是“错误单元格”，而是“合成记录 / 合成污染”。因此可以借鉴但不能照搬。

16.1 可以借鉴的地方

1. 表格序列化

ZeroED 把表格 tuple 转成文本：

```
{age: 39, education: Bachelor, occupation: Sales, income: <=50K}
```

你也可以这样把一条记录输入给 LLM。

2. schema + 示例 + 待测记录

ZeroED 强调上下文和指南。你可以设计 prompt：

```
你是数据质量专家。  
下面是 Adult 数据集 schema。  
下面是若干真实记录。  
请判断待测记录是否可能为合成数据。
```

3. 代表性采样降低成本

如果你要让 LLM 检测大量记录，可以先聚类或抽样，只让 LLM 标注代表记录，再训练分类器。

这与 ZeroED 的 hybrid 思路一致。

4. LLM 生成可解释理由

你可以要求 LLM 输出：

```
{
  "label": "synthetic",
  "confidence": 0.83,
  "reasoning": "age, occupation and income combination is uncommon..."
}
```

这能让你的 LLM 检测方法更可解释。

16.2 需要改造的地方

ZeroED 检测的是 cell-level error。

你的任务更偏 record-level / corpus-level synthetic detection。

因此：

- ZeroED 的单元格错误标签不能直接用。
- 你的标签是 real/synthetic。
- 你的检测对象是一整条记录，而不一定是某个单元格。
- 你的关注点是“过于规则、不像真实、分布偏差、组合异常”，而不是拼写或格式错误。

17. 综述中如何写 ZeroED

短版可以这样写：

Ni 等人提出的 ZeroED 是一种面向表格数据错误检测的混合式零样本框架，将 LLM 推理能力与传统机器学习检测流程结合起来。该方法通过 LLM 生成错误原因感知特征和检测指南，仅对聚类选出的代表性样本进行 LLM 标注，再通过标签传播、错误增强和验证机制构建训练数据，最终训练分类器完成大规模错误检测。ZeroED 表明，LLM 不仅可以直接给出判断，还可以作为表格数据治理流程中的规则生成器、标注器和语义增强器。本文借鉴这一范式，将 LLM 从表格错误检测扩展到合成表格数据污染检测，用于判断记录是否具有机器生成痕迹。

第三篇：Data Shapley

18. 基本信息

正式引用：

Amirata Ghorbani, James Zou.

Data Shapley: Equitable Valuation of Data for Machine Learning.

ICML 2019, PMLR 97:2242-2251.

PDF: <https://proceedings.mlr.press/v97/ghorbani19c/ghorbani19c.pdf>

这篇论文研究的是：

如何公平地衡量每一条训练数据对机器学习模型性能的贡献。

19. Data Shapley 想解决什么问题

在机器学习中，数据很值钱，但问题是：

一条具体的数据到底值多少钱？它对模型性能贡献有多大？

例如你有 1000 个病人的数据，用它们训练心脏病预测模型。你可能想知道：

- 哪些病人的数据最有价值？
- 哪些数据几乎没贡献？
- 哪些数据甚至是有害的？
- 如果要继续收集数据，应该收集哪类数据？

传统方法常用 leave-one-out：

把某条数据拿掉，重新训练模型，看性能下降多少。

但 leave-one-out 有缺陷。

例如每条数据都有一个一模一样的副本，拿掉其中一条不会影响模型，因为副本还在。leave-one-out 会认为每条数据价值都是 0，但这显然不合理。

Data Shapley 就是为了解决这种“数据之间有交互贡献”的问题。

20. Data Shapley 的基本思想

Data Shapley 借鉴合作博弈中的 Shapley value。

你可以把每条训练数据看成一个玩家：

玩家 = 训练数据点
合作结果 = 模型在测试集上的性能

某条数据的价值不是只看它单独有没有用，而是看：

它加入各种不同数据子集时，平均能带来多少性能提升。

换句话说，Data Shapley 计算的是一条数据的平均边际贡献。

21. 三个公平性性质

论文认为合理的数据估值应该满足三个性质。

21.1 无贡献则无价值

如果一条数据加入任何训练子集都不会改变性能，那么它价值为 0。

21.2 贡献相同则价值相同

如果两条数据在任何情况下带来的性能变化都一样，那么它们应该有相同价值。

21.3 可加性

如果总任务由多个子任务组成，一条数据对总任务的价值应等于它对各子任务价值之和。

论文证明，满足这些性质的数据估值形式就是 Shapley value。

22. 为什么精确计算很难

如果有 n 条数据，所有数据子集数量是指数级的。

精确 Data Shapley 需要遍历大量子集，并对每个子集重新训练模型，计算成本极高。

所以论文提出近似方法。

23. 论文提出的近似方法

23.1 Monte Carlo Shapley

随机打乱数据顺序，逐个加入数据，记录每条数据加入时带来的性能提升。

重复很多次，取平均。

直觉：

在很多种随机加入顺序下，一条数据平均能带来多少提升？

23.2 Truncated Monte Carlo Shapley

当模型性能已经接近完整数据集性能时，后面再加数据的边际贡献通常很小。

因此可以提前停止后续计算，节省时间。

23.3 Gradient Shapley

对神经网络等复杂模型，反复完整训练太贵。论文提出基于梯度更新的近似方法，用一次训练过程中的性能变化估计数据贡献。

23.4 Group Shapley

如果数据太多，可以不算每条记录，而是算一组数据的价值。

例如按性别、年龄、种族分组，计算某个群体数据的价值。

这对你的毕设尤其有用，因为你可以计算：

- 真实数据组的价值。
 - 合成数据组的价值。
 - 不同污染比例下数据组的价值变化。
-

24. 论文实验结论

论文展示了 Data Shapley 的多个用途。

24.1 找出高价值数据

移除高 Shapley 值的数据，模型性能下降明显。

这说明高 Shapley 数据确实对模型重要。

24.2 找出低价值或负价值数据

移除低 Shapley 值的数据，有时模型性能反而提升。

这说明低价值数据可能是噪声、异常点或有害样本。

24.3 识别错误标签和腐坏数据

论文发现：

- 标签翻转的数据往往有低 Shapley 值。
- 加噪声的图片 Shapley 值更低。

这对你的毕设有启发：

如果合成数据损害下游模型，它们可能表现为低 Shapley 或负 Shapley 数据。

24.4 指导数据采集

收集与高价值数据相似的新数据，比随机收集更能提升模型性能。

25. Data Shapley 和你的毕设有什么关系

你的任务三是：

分析合成污染对数据估值的影响。

Data Shapley 正是这个任务的基础工具。

你可以用它回答：

1. 合成记录的平均 Shapley 值是否低于真实记录？
2. 污染比例越高，整体数据价值是否下降？
3. 哪些类型的合成记录是负贡献？
4. 混入合成数据后，真实数据的 Shapley 分布是否被改变？
5. 合成数据是否会错误抬高某些下游任务表现？

26. 你可以怎么设计估值实验

26.1 最简单版本

先不要直接算完整 Shapley。

可以定义：

$$V(D) = \text{用数据集 } D \text{ 训练模型后，在真实测试集上的 AUROC 或 F1}$$

然后比较：

$$\Delta V(p) = V(D_{\text{mixed}}(p)) - V(D_{\text{real}})$$

这就是说明书中的估值偏差。

26.2 Shapley 版本

如果时间允许，可以进一步：

1. 构造真实 + 合成混合训练集。
2. 对训练记录计算近似 Shapley 值。
3. 比较真实记录和合成记录的 Shapley 分布。
4. 看污染比例变化时 Shapley 分布如何变化。

例如：

数据类型	平均 Shapley
真实记录	0.0031
CTGAN 合成记录	0.0012
TVAE 合成记录	0.0017

如果合成记录平均贡献更低，说明它们对下游任务价值较弱。

26.3 对照实验很重要

要避免把“数据量增加”误认为“合成数据有效”。

应该比较：

- 加入 1000 条合成数据。
- 加入 1000 条真实数据。

两者差异才更接近“合成污染”的净效应。

27. 综述中如何写 Data Shapley

短版可以这样写：

Ghorbani 和 Zou 提出的 Data Shapley 将合作博弈中的 Shapley value 引入机器学习数据估值，认为每条训练数据的价值应由其对模型预测性能的平均边际贡献决定。该方法满足无贡献为零、对称性和可加性等公平估值性质，并通过 Monte Carlo、截断 Monte Carlo 和梯度近似等方法缓解精确计算的指数复杂度。实验表明，Data Shapley 能识别高价值样本、噪声样本和错误标签，并可指导后续数据采集。本文借鉴 Data Shapley 作为数据估值工具，用于分析合成表格数据污染对下游模型效用及单条记录价值分布的影响。

三篇文献如何共同支撑你的毕设

28. 逻辑链条

这三篇文献可以组成一条非常清楚的综述逻辑：



这条线非常适合写在你的文献综述或研究动机中。

29. 综述整合段落：可直接改写

你可以在文献综述中这样写：

随着生成式模型在文本、图像和表格数据生成中的广泛应用，模型生成数据混入后续训练集所带来的风险逐渐受到关注。Shumailov 等人在 Nature 2024 中提出 model collapse 现象，指出模型若递归地使用前代模型生成的数据进行训练，会逐渐丢失真实分布中的尾部信息，并导致不可逆的分布退化。这一发现说明，在模型生成数据大量存在的环境下，识别数据来源并检测合成污染具有重要意义。

在表格数据治理方面，Ni 等人提出的 ZeroED 展示了 LLM 赋能检测的有效范式。ZeroED 并非简单地让 LLM 逐条判断错误，而是通过 LLM 生成错误原因感知特征和检测指南，对代表性样本进行零样本标注，再结合标签传播和错误增强训练传统分类器，实现低人工成本、低 token 成本的表格错误检测。该工作为本文设计 LLM 赋能的合成表格数据检测方法提供了直接参考。

除了检测合成污染本身，本文还关注合成污染对数据价值的影响。Ghorbani 和 Zou 提出的 Data Shapley 为训练数据估值提供了理论框架，将每条训练样本的价值定义为其对模型性能的平均边际贡献，并可通过 Monte Carlo 等方法近似计算。本文借鉴该思想，比较不同污染比例下真实数据与合成数据的价值分布及下游效用变化，从而量化合成污染对表格数据价值的影响。

30. 你写文献小结时的模板

30.1 模型坍缩论文

论文解决什么：

研究生成模型递归使用模型生成数据训练时是否会退化。

核心思路：

从理论和实验上说明模型生成数据污染训练集会导致尾部分布消失、方差降低和模型坍缩。

对毕设的作用：

提供研究合成表格数据污染检测的根本动机，说明合成数据混入训练管线可能造成分布退化和下游风险。

30.2 ZeroED

论文解决什么：

在无人工规则和无人工标签的情况下检测表格数据错误。

核心思路：

用 LLM 生成错误原因感知特征、检测指南和少量代表样本标签，再训练传统分类器完成大规模检测。

对毕设的作用：

提供 LLM 赋能表格检测的范式，可迁移到合成记录检测中的 prompt 设计、代表性采样、LLM 标注和分类器训练。

30.3 Data Shapley

论文解决什么：

公平量化单条训练数据对机器学习模型性能的贡献。

核心思路：

将训练数据视为合作博弈中的玩家，用 Shapley value 计算每条数据在不同子集中的平均边际贡献。

对毕设的作用：

作为估值影响分析的理论基础，用于比较真实记录和合成记录的价值，以及污染比例变化对下游效用的影响。

31. 最终总结

这三篇文献分别回答了你毕设中的三个关键问题：

1. 为什么做？

模型坍缩论文说明合成数据污染可能导致长期分布退化，因此需要检测和治理。

2. 怎么做一个有特色的检测方法?

ZeroED 说明 LLM 可以通过推理、规则生成、代表样本标注和混合式 ML 管线参与表格检测。

3. 检测之后分析什么影响?

Data Shapley 提供数据估值方法，可以衡量合成污染对单条记录价值和整体数据效用的影响。

用一句话总结：

模型坍缩论文给出问题动机，ZeroED 给出 LLM 表格检测方法范式，Data Shapley 给出估值分析工具；三者共同构成你毕设“检测合成污染并分析其影响”的理论和方法支撑。